

# 广告营销uplift分享

## Part I 【从黑夜到黎明】

怎样在AB评估场景下，构建一套合理的RTB策略

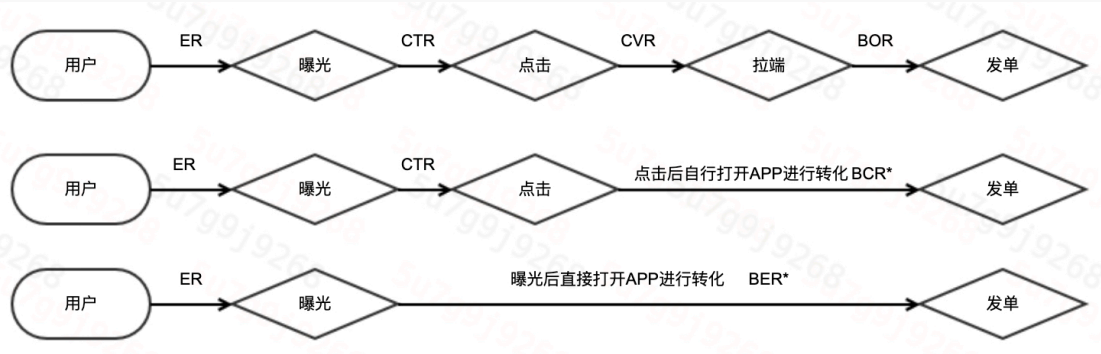
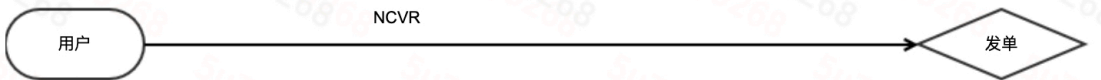
### 一、为什么Uplift

#### 1.1、背景&问题

当前DSP基于AB评估的业务 (网约车存量新、沉默用户、流失用户)，采用CTCVR预估模型(7日内转化模型)+CPA出价的方式。此方案应对于CAC归因的评估方式是可行的，因为归因评估不需要考虑反事实，即被广告干预过(7天未次归因)即为(广告+渠道礼包)影响的转化。

但在应对于AB评估场景下，该出价方式是不合理的，若用户 <自然转化率高、且广告预估CTCVR同样高>，则广告干预带来的转化净增量 $\Delta CTCVR = CTCVR - NCVR$ (自然转化率)相对较低，但由于CTCVR较高，我们基于CPA出价 $price = CTCVR \cdot bid$ 会较高，而由于点击率高，该广告背后的二价往往也相对较高，这导致我们此次出价的ROI较低， $ROI = \frac{\Delta CTCVR}{price_{second}}$ 。

注变量说明:

名称	变量名	变量说明
整体转化率	TCVR	用户7日内整体转化率，包括曝光、点击转化、自然转化等
广告干预转化率	CTCVR	<div>包括曝光转化、点击转化、点击后延迟转化</div> <div></div>
自然转化率	NCVR	<div>无广告干预下的转化率</div> <div></div>

## 二、Uplift出价怎么做

### 2.1、目标拆解

若我们每日的广告投放预算一定，则我们可将广告投放建模为预算约束下，最大化首单（首呼）增量的形式即：

$$\begin{aligned} & maximize \sum_i \Delta iorder_i \\ & s.t. \sum_{ij} cost_{ij} \leq budget \\ & cost_{ij} = X_{ij} \cdot price_{ij} \cdot accept\_prob_{ij} \end{aligned}$$

其中

变量	含义
$i$	乘客i
$j$	与乘客i对应的第j个请求
$iorder_i$	乘客i广告投放周期内是否有过发单
$cost_{ij}$	对第ij个请求的开销
$X_{ij}$	决策变量: 是否对ij请求进行bid
$price_{ij}$	广告二价
$accept\_prob_{ij}$	媒体方接受我们广告的概率

#### 可加性假设

因为单次曝光对整体首单的影响比较难建模，我们做出可加性假设，对于每个用户，其首单增量=每次曝光对首单的增量之和，即

$$\Delta iorder_i = \sum_j iorder_{ij}$$

#### 最优出价公式

若供给方平台请求均严格按照二价竞拍，则对于任意一个请求其最终结算金额 $price_{ij}$ 是客观固定的，而其价值 $\Delta iorder_{ij}$ 也是客观的。则我们有对于任意一个请求，其首单ROI与我们的出价无关，为

$$ROI_{ij} = \frac{\Delta iorder_{ij} \cdot accept\_prob_{ij}}{price_{ij} \cdot accept\_prob_{ij}} = \frac{\Delta iorder_{ij}}{price_{ij}}$$

则目标中的规划模型，可转化为购买头部ROI的请求（确定一个ROI阈值 $ROI_0$ ），使得我们当天的花费等于当天预算。

我们有出价公式

$$price_{ij}^{bid} = \Delta iorder_{ij} \cdot \frac{1}{ROI_0}$$

## 最优性证明

对于 $\forall$ 一个请求 $ij$ ，我们出价 $price_{ij}^{bid} = \Delta iorder_{ij} \cdot \frac{1}{ROI_0}$ ，考虑两种情况：

1.  $ROI_{ij} \geq ROI_0$ ，其二价 $price_{ij} = \Delta iorder_{ij} \cdot \frac{1}{ROI_{ij}} \leq price_{ij}^{bid}$ ，若不存在频控的问题，该条广告我们会竞得
2.  $ROI_{ij} < ROI_0$ ，其二价 $price_{ij} = \Delta iorder_{ij} \cdot \frac{1}{ROI_{ij}} > price_{ij}^{bid}$ ，该条广告我们不会竞得

因此我们按照 $price_{ij}^{bid} = \Delta iorder_{ij} \cdot \frac{1}{ROI_0}$ 进行出价，对于低于 $ROI_0$ 的请求我们都会舍弃，对于高于 $ROI_0$ 的请求我们在无频控的情况下，均可竞得。即在花费一定的情况下，购买头部ROI的请求。

## 歪楼：CPA出价公式

为什么在采用归因评估的时候，我们采用CPA出价公式？

在归因评估时，我们的目标为

$$\text{maximize } \sum iorder_{ij}^{Int} = \sum ctcvr_{ij}$$

变量名	含义
$iorder_{ij}^{Int}$	归因给广告干预的首单数，采用点击归因则为点击后转化的首单量


对于一个请求来说，首单ROI即为：

$$ROI_{ij} = \frac{iorder_{ij}^{Int} \cdot accept\_prob_{ij}}{price_{ij} \cdot accept\_prob_{ij}} = \frac{iorder_{ij}}{price_{ij}} = \frac{ctcvr_{ij}}{price_{ij}}$$

重新采用最优性证明即可证得CPA出价为最优出价。

## 2.2、模块拆解

因此我们线上的Pipeline如下



主要算法模块: uplift model

## 2.3、uplift model建模方案

### 1、观测数据建模

由于1. 随机试验数据成本过高、2. 供给方平台的限制，在广告营销场景中较难收集完全的随机实验数据，因此我们需要考虑从观测数据的建模方案。

观测数据建模要求条件：

### 1. Stable Unit Treatment Value Assumption (SUTVA)

样本之间潜在结果相互独立, 且同一个处理水平的潜在结果一致 (consistency), 即  $Y_i = Y_i(T)$

### 2. Ignorability

给定观测变量  $X$ , 潜在结果  $Y(0)$  与处理变量  $Y(1)$  之间条件独立, 即  $Y(0), Y(1) \perp T | X$

### 3. Positivity

对于任意  $X \in \mathcal{X}$ , 在数据中观测到任意  $t \in \{0, 1\}$  的概率都不为0

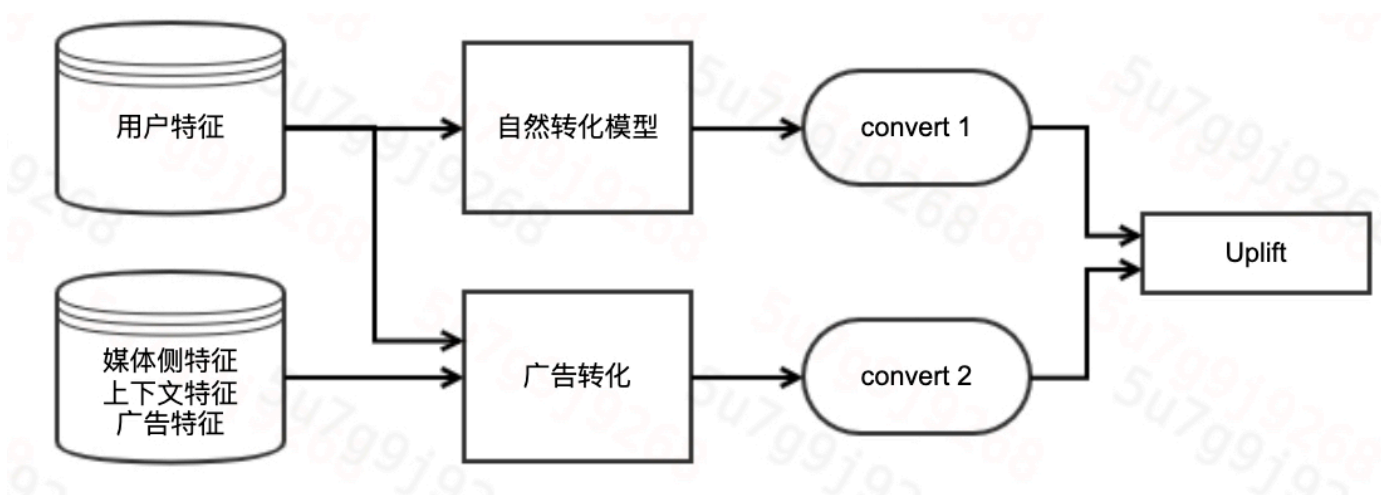
在广告系统中, 实验组人群存在重复曝光的可能, 因此条件1被违背。

## 假设2

若我们进一步假设多次曝光的处理效应与单次曝光的处理效应相同, 则条件1可满足

## Step I、<上线> T-learner

由于当前EVE平台支持的限制, 我们在第一步选用XGB作为基模型, 考虑CFR的思路对样本进行样本ipw去偏, 构建T-learner。



训练步骤:

1. 构建倾向性分数模型 (广告被曝光的概率)
2. 将倾向性分数的预估结果作为实验组(被曝光的广告)样本的加权
3. 加权后的样本, 构建CTCVR模型
4. 对照组样本作为自然转化模型

## Step II、<迭代> 基于表示学习 | 基于树模型

表示学习(深度): 在系统支持深度模型后, 可接入Tar-net、CFR、Dragon-net

树模型: causal forest、grf + doubly robust、causal forest dml

# Part II 【从黎明到天亮】

因果推断简单介绍 => uplift Model & 补贴的应用 => 我们当前场景下要面临的挑战

## 一、因果推断

# 1.1、辛普森悖论

Covid-27 病症严重度 VS Treatment表

Treatment	轻度死亡率	重度死亡率	汇总死亡率
A组(T=0)	15% (1400中有210死亡)	30% (100人中30人死亡)	16%
B组(T=1)	10% (50人中5人死亡)	20% (500人中100人死亡)	19%

$P(Y|T = 1) > P(Y|T = 0)$

由于选择性偏差，我们直接对  $Y$  VS  $T$  进行相关性建模，会得到结论


药物治疗对于Covid-27病症会产生负向影响。

这个结论显然是有问题的，谬误的原因在于

相关性不等于因果性

# 1.2、因果图&因果推断中的基本概念

一个相对比较全的因果干预图



变量	变量名	变量说明
Treatment	$T$	是否进行干预(广告、吃药等)
调整变量	$X_1$	只对结果response产生影响的量(自然转化率等)
混淆变量	$X_3$	对是否进行干预Treatment和结果reponse同时产生影响的变量
工具变量	$X_4$	只对treatment产生影响的变量
调节变量	$X_2$	对treatment的影响程度产生影响的量，用户异质性的来源
中介变量	$M$	treatment对其产生直接影响，但对结果产生间接影响的量
Response	$Y$	干预的结果，例如转化率，致死率，痊愈率等 $Y_0 = E(Y T = 0)$ $Y_1 = E(Y T = 1)$
ATE	$ATE$	Average treatment effect $ATE = Y_1 - Y_0$ ， 因果推断中最关注的结果变量，在我们场景中为广告干预带来的增量， 在上述例子中，ATE表述的是药物治疗对致死率的改善量

回到我们刚刚的辛普森悖论问题，导致我们得到错误结论的来源是病症严重度，其属于混淆变量X3，其影响了治疗率(Treatment)的同时，影响了致死率(Response Y)。

### 1.3、针对选择性偏差进行纠偏

由 $ATE = Y_1 - Y_0$ 可知，若我们可对response Y进行无偏估计，那自然可以对ATE进行无偏估计

变量	变量名	变量说明
指示变量	$R$	实验组中 $R = 1 \text{ if } T = 1$ 对照组中 $R = 1 \text{ if } T = 0$
倾向性分数	$Pr(T X)$	每个用户基于其特征，被干预的概率

#### A. Outcome regression estimator

建模模型 $Y_i = m(X_i, \beta)$

loss函数:  $\sum_{i=1}^N R_i(Y_i - m(X_i, \beta))^2$

则 $Y = N^{-1} \cdot \sum_{i=1}^N m(X_i, \beta)$

#### B. Inverse propensity score weighted estimator

建模倾向性分数模型

$\pi(X_i, \gamma) = P(R = 1|X)$

则 $Y = N^{-1} \sum_{i=1}^N \frac{R_i Y_i}{\pi(X_i, \gamma)}$

## C. Doubly Robust

$$Y = N^{-1} \sum_{i=1}^N \left\{ \frac{R_i Y_i}{\pi(X_i, \gamma)} - \frac{R_i - \pi(X_i, \gamma)}{\pi(X_i, \gamma)} m(X_i, \beta) \right\}$$

该表达式有良好的特性: 回归模型 $m$ 与倾向性分数 $\pi$ 只要有一个是无偏估计就使得结果无偏, 证明如下

$$\begin{aligned} E \left\{ \frac{RY}{\pi(X, \gamma^*)} - \frac{R - \pi(X, \gamma^*)}{\pi(X, \gamma^*)} m(X, \beta^*) \right\} \\ = E \left[ Y + \left\{ \frac{R - \pi(X, \gamma^*)}{\pi(X, \gamma^*)} \right\} \{Y - m(X, \beta^*)\} \right] \\ = \mu + E \left[ \left\{ \frac{R - \pi(X, \gamma^*)}{\pi(X, \gamma^*)} \right\} \{Y - m(X, \beta^*)\} \right] \end{aligned}$$

### 无偏性

我们由损失函数得到的参数统计量的期望为真值, 但不需保证收敛。

### 相合性

在一次实验中取样个数 $n$ 一直增大的情况下, 只要 $n$ 越来越大, 最终估计出来的参数会趋近于真实的参数, 期望可以有偏, 但需要收敛到真值。

## D. Double Machine Learning

本质问题

$$Y = T \cdot \theta + g_0(X) + U \quad E[U|X, T] = 0$$

$$T = \pi(X) + V \quad E[V|X] = 0$$

我们需要预估  $\theta$  即为ATE (平均处理效应)。拆成两步进行估计

1. 数据分成两个部分, 在其中一个部分上估计 $g$ 模型& $\pi$ 模型
2. 利用估计到的 $g, \pi$ , 在另一部分数据上用线性回归得到想要的估计量

若直接回归 $Y = T \cdot \theta + g_0(X)$ , 由于加入正则项等, 收敛速率会更慢, 甚至会导致预估非相合估计, 即收敛不到期望真值。

## 二、Uplift模型

与传统因果推断中专注于ATE的估计不同, Uplift模型专注于CATE(ite有些片面)估计(Conditional ATE)

### 2.1、Meta-learners

模型	建模思路	问题&改进点
Slearner	直接建模 $Y = f(X, T)$ 则 $\tau(X) = Y(X, 1) - Y(X, 0)$	低维T特征容易淹没在高维X特征中，受选择性偏差的影响很大
Tlearner	建模两个模型 $Y_1 = f_1(X), Y_0 = f_0(X)$ 则 $\tau(X) = f_1(X) - f_0(X)$	若实验组数据&对照组数据分布差别较大，拆成两个模型之后仍旧无法估计 相比treatment来说，response的噪声可能更大。
Xlearner	$\mu_0 = \mathbb{E}[Y(0) X = x]$ $\mu_1 = \mathbb{E}[Y(1) X = x]$ $\tilde{D}_i^1 := Y_i^1 - \hat{\mu}_0(X_i^1)$ $\tilde{D}_i^0 := \hat{\mu}_1(X_i^0) - Y_i^0$  $\hat{\tau}(x) = g(x)\hat{\tau}_0(x) + (1 - g(x))\hat{\tau}_1(x)$	改进点: 在实验组数据量较少，预估偏差方向与对照组模型不一致，导致利用T-learner时， $\tau$ 计算结果偏差较大

## 2.2、Causal Tree

模型	建模思路
causal tree	相对于回归树或分类树，其分裂标准为计算节点内ATE，若分裂后ATE相比分裂前更大，则进行分裂
causal forest	1. Honest Tree：对节点内样本随机分成两部分，一部分用于分裂一部分用于估计CATE，另一部分用于作为分裂不纯度 2. 将causal tree集成为causal forest
Grf generalized random forest	相对于causal forest，在计算节点内ATE时加入了，doubly robust，dml等方法，并可自定义分裂标准
连续因果森林	由计算CATE改为计算CAPE(conditional average partial effect) 因为在C补场景下，可以自定义折扣级别，假设增量与折扣系数成正相关，进行建模

## 2.3、基于深度学习

模型	建模思路



### Algorithm 1 Balancing counterfactual regression


- 1: **Input:**  $X, T, Y^F; \mathcal{H}, \mathcal{N}; \alpha, \gamma, \lambda$
- 2:  $\Phi^*, g^* = \arg \min_{\Phi \in \mathcal{N}, g \in \mathcal{H}} B_{\mathcal{H}, \alpha, \gamma}(\Phi, g) \quad (2)$
- 3:  $h^* = \arg \min_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n (h(\Phi, t_i) - y_i^F)^2 + \lambda \|h\|_{\mathcal{H}}$
- 4: **Output:**  $h^*, \Phi^*$

$$B_{\mathcal{H}, \alpha, \gamma}(\Phi, h) = \frac{1}{n} \sum_{i=1}^n |h(\Phi(x_i), t_i) - y_i^F| + \quad (2)$$

$$\alpha \text{disc}_{\mathcal{H}}(\hat{P}_{\Phi}^F, \hat{P}_{\Phi}^{CF}) + \frac{\gamma}{n} \sum_{i=1}^n |h(\Phi(x_i), 1 - t_i) - y_{j(i)}^F|,$$

损失函数分3部分:

1. 事实数据误差
2. 事实模型&反事实模型对应的特征分布是近似的
3. 与反事实数据最近事实数据对应的loss



$$\min_{\substack{h, \Phi \\ \|\Phi\|=1}} \frac{1}{n} \sum_{i=1}^n w_i \cdot L(h(\Phi(x_i), t_i), y_i) + \lambda \cdot \mathfrak{R}(h)$$

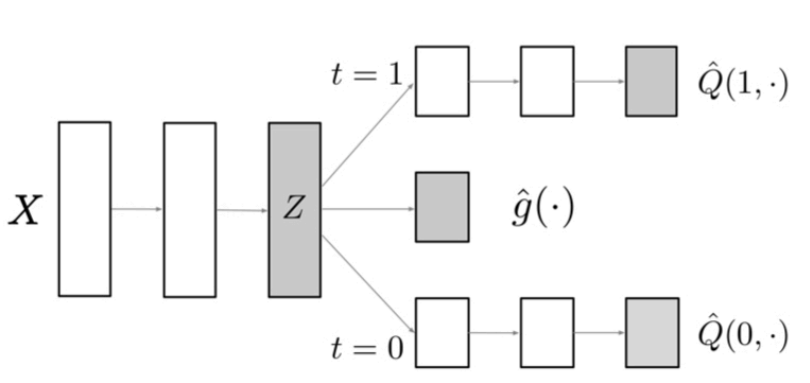
$$+ \alpha \cdot \text{IPM}_G(\{\Phi(x_i)\}_{i:t_i=0}, \{\Phi(x_i)\}_{i:t_i=1}),$$

with  $w_i = \frac{t_i}{2u} + \frac{1-t_i}{2(1-u)}$ , where  $u = \frac{1}{n} \sum_{i=1}^n t_i$ ,

and  $\mathfrak{R}$  is a model complexity term.

损失函数包括两部分:

1. 加权事实数据误差
2. 实验组&对照组分布的差异

ACE	$\mathcal{L} = \mathcal{L}_f + \alpha \mathcal{L}_d + \gamma \mathcal{L}_s + \lambda (\ \Theta_{rep}^{-bias}\ _2 + \ \Theta_c^{-bias}\ _2 + \ \Theta_t^{-bias}\ _2)$ <p>建模思路:</p> <ol style="list-style-type: none"> <li><math>\mathcal{L}_s(\mathcal{P}, \mathcal{Q}) = - \sum_{i,j} \mathcal{P}_{i,j} \log \frac{\mathcal{Q}_{i,j}}{\mathcal{P}_{i,j}}</math> KL散度</li> </ol> <p>希望representation之前用x计算出倾向性得分相近的两个个体，representation之后，representation之间的距离还是相近</p> $\mathcal{L}_s(\mathcal{P}, \mathcal{Q}) = - \sum_{i,j} \mathcal{P}_{i,j} \log \frac{\mathcal{Q}_{i,j}}{\mathcal{P}_{i,j}},$ <p>where <math>\mathcal{P}</math> denotes the joint probability of <math>\mathbf{x}_i</math> and <math>\mathbf{x}_j</math>: <math>\mathcal{P}_{i,j} = \frac{\exp(S(\mathbf{x}_i, \mathbf{x}_j))}{\sum_{k \neq l} \exp(S(\mathbf{x}_k, \mathbf{x}_l))}</math> with <math>S(\cdot, \cdot)</math> being the similarity function;  And <math>\mathcal{Q}</math> denotes the joint probability of <math>\mathbf{R}_i</math> and <math>\mathbf{R}_j</math>, which is calculated as: <math>\mathcal{Q}_{i,j} = \frac{\exp(-\ \mathbf{R}_i - \mathbf{R}_j\ ^2)}{\sum_{k \neq l} \exp(-\ \mathbf{R}_k - \mathbf{R}_l\ ^2)}</math>.</p> $S(\mathbf{x}_i, \mathbf{x}_j) = 0.75 \left  \frac{f_{prop}(\mathbf{x}_i) + f_{prop}(\mathbf{x}_j)}{2} - 0.5 \right  - 0.5  f_{prop}(\mathbf{x}_i) - f_{prop}(\mathbf{x}_j)  + 0.5$
Dragon-net	<p>本意是建模ATE</p>  <p>多了一个输出propensity score的头，希望模型更关注于混淆变量</p>

## 2.4、营销补贴场景的应用

补贴类型	应用方式
离线补贴	<ol style="list-style-type: none"> <li>1. uplift建模、花费建模</li> <li>2. 弹性 = uplift / 花费</li> <li>3. 选取高弹性用户营销补贴</li> </ol>
在线补贴	<ol style="list-style-type: none"> <li>1. uplift建模、花费建模</li> <li>2. 弹性 = uplift / 花费</li> <li>3. 差分背包求解离线补贴折扣</li> <li>4. 输出线上等价折扣模型<a href="http://way.xiaojukeji.com/article/26660">http://way.xiaojukeji.com/article/26660</a></li> </ol>

### 三、我们的挑战

#### 3.1、模型部分

问题点	说明
实验组特征&对照组特征维度差异	实验组会包括媒体信息，上下文信息等特征；而对照组中这些特征无法取到，即使特征存在于unbid表中，多account_id情况下也不容易匹配。 1. 这些信息均与首单增量相关，如何将这些特征应用到uplift建模中。 2. 即使可以对实验组增量进行预估，如何借鉴QINI score的思路对预估结果进行评估
uv=>pv建模	当前用户会存在多次曝光的问题，因此难以度量每次曝光带来的增量。我们现在的做法是针对实验组、对照组均通过UV粒度建模，而UV粒度建模相对于PV粒度会丢失部分信息。
观测数据纠偏	因为我们的分流周期较长，因此空白组用户长期未被广告干预，其特征与实验组的差距会越来越大。一种合理的方法是采用观测数据建模减弱相关特征的重要性。
向深度 &causal tree 推进	当前Meta learner的思路较为原始，但复杂模型对数据的要求较高，怎样向更有力的建模方式过渡。

#### 3.2、出价部分

问题点	说明
券补	当前出价公式为仅考虑渠道花费的最优出价，如何综合考量券补。
预估偏差	当前出价公式未考虑增量预估偏差，特别是在不同增量范围内偏差不同时，采用当前出价公式，会对整体成本有较大影响。
防作弊	当前出价公式最优性证明是基于ADX二价结算的，如何在考虑ADX作弊情况下，进行最优出价

#### 3.3、自动化出价

问题点	说明
两个自动化 出价方向	纯黑盒 <端到端建模> *CEM DDPG 白盒建模 媒体流量预估 & 规划 & 出价回归模型
纳什均衡	当前出价均是基于业务线最低成本的考量，而非从DSP角度出发，若不同业务线预算有差异，则会出现内卷严重问题，流量流向低效用业务线。

因果推断技术交流群

DCIRG - 滴滴因果推断研究小组<https://cooper.didichuxing.com/team-file/56040>